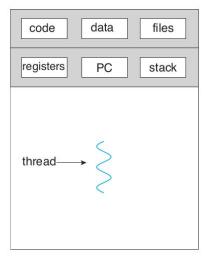
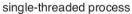
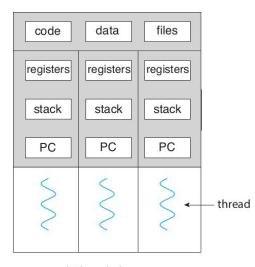


Wątek

- Wątek to podstawowa jednostka wykorzystania procesora.
- Wątek zawiera: identyfikator (numer), licznik programu, rejestry oraz stos.
- Wątek współdzieli z innymi wątkami należącymi do tego samego procesu: sekcję kodu, sekcję danych oraz inne zasoby systemu operacyjnego (np. otwarte pliki, sygnały).







multithreaded process

Wątek

Proces

- Proces osadzony jest w dwóch charakterystykach:
 - Właściciela zasobów, w tym przestrzeni adresowej zawierającej obraz procesu.
 - Planowania i wykonywania, która przeplata się razem z innymi procesami.
- Te dwie wyżej wymienione charakterystyki są niezależnie traktowane w systemie operacyjnym.

Wątek

- Jednostką wykonywanego zadania jest wątek, inaczej lekki proces (ang. lightweight process).
- Właściciel określony jest przez proces (zadanie), do którego wątek należy.

Proces

- Proces to wykonywany program.
- Heavy weight process.
- Czaso- i zasobochłonne: tworzenie, terminacja, przełączanie kontekstu.
- Komunikacja: pamięć dzielona lub wymiana komunikatów jako mechanizmy specjalne.
- Procesy są izolowane.
- Przełączanie procesów odbywa się przez funkcje systemowe.
- Dla jądra dwa procesy to dwa procesy.
- Zablokowanie jednego procesu nie wpływa na fakt zablokowania innego procesu.

vs. Wątek

- Wątek to część danego procesu.
- Lightweight process.
- Szybsze i zużywające mniej zasobów na tworzenie, terminację i przełączanie kontekstu.
- Komunikacja: bezpośrednio współdzielone wszystkie zasoby danego procesu.
- Watki współdziela.
- Przełączanie wątków odbywa się bez wywoływania przerwań do jądra.
- Dla jądra dwa wątki to jeden proces.
- Zablokowanie procesu, to zablokowanie jego wszystkich wątków.

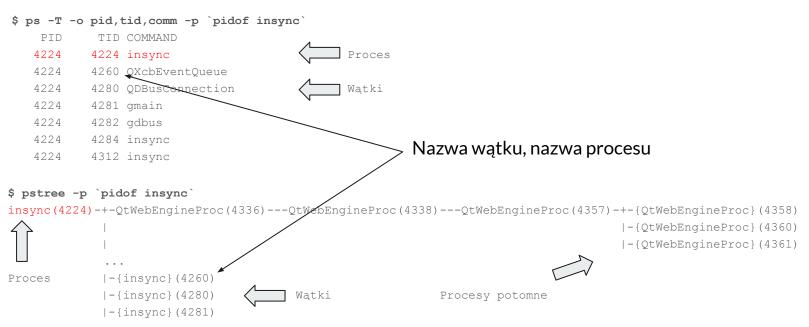
Proces

- Zablokowanie się procesu macierzystego uniemożliwia tworzenie procesów potomnych.
- Proces ma własny PCB, stos oraz przestrzeń adresową.
- Zmiany w procesie macierzystym nie mają wpływu na procesy potomne.

vs. Wątek

- Zablokowanie pierwszego wątku nie wpływa na działanie pozostałych wątków procesu.
- Ma rodzica PCB, własny TCB, stos oraz współdzieloną przestrzeń adresową.
- Zmiany w procesie wpływają na zmiany w wątkach tego procesu.

Obserwowanie wątków w systemie Linux



PID vs. TID

- PID = process identifier
- TID = thread identifier
- Jeśli proces ma tylko jeden wątek, to PID == TID
- Jeśli proces ma wiele wątków, to pierwszy z nich ma unikalny TID w zakresie tego procesu
- Jądro systemu nie rozróżnia szczególnie wątku od procesu
- Dla jądra wątki to procesy, które współdzielą pewne zasoby
- Kiedy tworzymy nowy proces za pomocą fork (), to otrzymuje on nowy PID i TID (PID==TID)
- Kiedy tworzymy nowy wątek to otrzymuje on PID taki jak procesu oraz nowy TID.
- Alias: LWP = Light-Weight Process

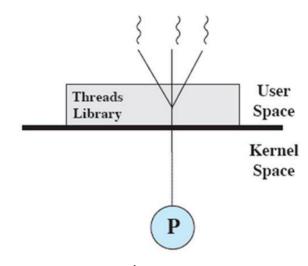
Obserwowanie wątków kernela w Linux

Dlaczego mają odmienny PID?

Dlatego, że to jest TID.

Wątki na poziomie użytkownika

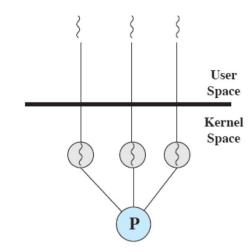
- Zarządzanie wątkami odbywa się na poziomie aplikacji.
- Jądro nie ma wiedzy na temat wątków.



Źródło: TODO

Wątki na poziomie jądra

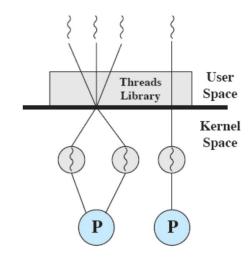
- Jądro zarządza kontekstem dla procesu oraz wątków.
 Nie ma zarządzania wątkami na poziomie aplikacji.
- Zalety:
 - Kernel może jednocześnie planować realizację wielu wątków z jednego procesu na wielu procesorach/rdzeniach.
 - Jeśli jeden wątek w procesie jest zablokowany, jądro może planować inny wątek tego samego procesu.
 - Funkcjonalność jądra może być wielowątkowa.
- Wada: przekazanie kontroli między wątkami w obrębie procesu wymaga kernel-mode.



Źródło: TODO

Rozwiązanie łączone

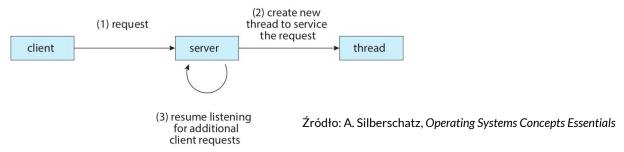
- Tworzenie wątku odbywa się w przestrzeni użytkownika.
- Planowanie (scheduling) oraz synchornizacja wątków odbywa się w jądrze



Źródło: TODO

Wątki - zastosowania

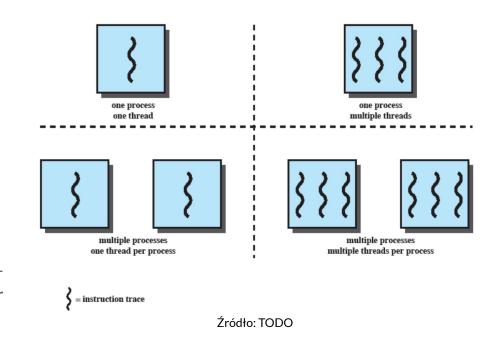
- Program serwera obsługujący żądania (ang. requests) programów klienckich:
 - Serwer stron WWW i przeglądarka internetowa.
 - Serwer poczty elektronicznej (ang. mail transfer agent) i program pocztowy.
 - Sprawdzanie pisowni w edytorze tekstu.
- Prowadzenie obliczeń macierzowych:
 - Wykonywanie operacji na tych samych danych.



Uwaga! Tworzenie wątku jest mniej obciążające niż tworzenie nowego procesu.

Wielowątkowość

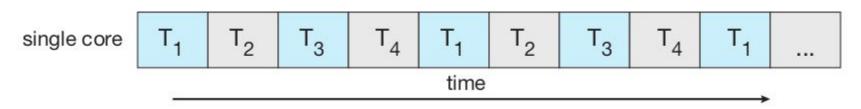
- Zdolność systemu operacyjnego do wspierania wielu ścieżek wykonywania w obrębie jednego procesu.
- MS-DOS single user process with single thread.
- Some UNIX multiple user processes with single thread per process.
- Java run-time env. single process with multiple threads.
- Windows, Solaris, modern UNIX, Linux, etc. multiple processes with multiple threads per process.



Zalety oprogramowania wielowątkowego

- Responsywność jeśli część aplikacji jest zablokowana, inna jej część może wykonywać operacje, a cała aplikacja sprawia wrażenie ciągłego działania. Zastosowanie: w aplikacji, kiedy jedna wywołana operacja wykonywana jest w tle, interfejs użytkownika pozostaje responsywny.
- Współdzielenie zasobów w przypadku procesów współdzielenie zasobów odbywa się tylko poprzez pamięć współdzieloną, albo przesyłanie komunikatów. Wątki współdzielą zasoby wprost. Współdzielenie kodu i danych umożliwia wątkom działać w tej samej przestrzeni adresowej.
- Ekonomia alokowanie pamięci i zasobów przy tworzeniu procesu jest bardziej kosztowne, niż w przypadku wątków. Przełączanie przełączanie kontekstu jest także szybsze w przypadku wątków.
- **Skalowalność** aplikacje wielowątkowe mogą działać w architekturze wielordzeniowej. Aplikacja jednowątkowa może być wykonana tylko na jednym rdzeniu procesora.

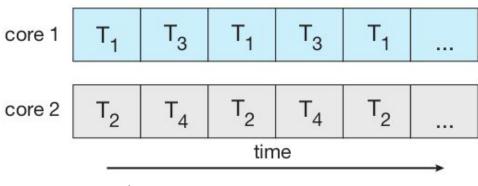
Współbieżność i równoległość



Źródło: A. Silberschatz, Operating Systems Concepts Essentials

Współbieżność (ang. concurrency) - umożliwia więcej niż jednemu zadaniu być wykonywanym. Do realizacji współbieżności nie jest wymagany system wielordzeniowy.

Współbieżność i równoległość



Źródło: A. Silberschatz, Operating Systems Concepts Essentials

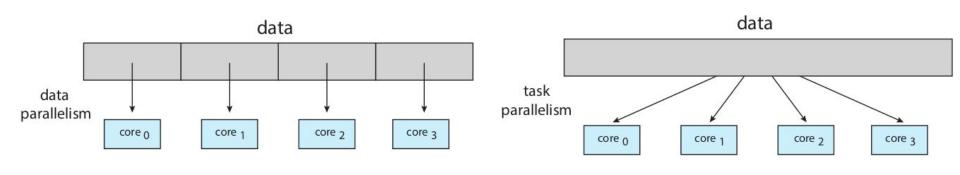
Równoległość (ang. *parallelism*) - umożliwia więcej niż jednemu zadaniu być wykonywanym **JEDNOCZEŚNIE**. Do realizacji równoległości jest wymagany system wielordzeniowy.

Pytanie: czy może zaistnieć współbieżność bez równoległości?

Wyzwania programowe

- Identyfikacja zadań, w szczególności na zadania niezależne między sobą.
- Balansowanie zadaniami celem zrównoważenia obciążenia.
- **Dzielenie danych** między wydzielone zadania.
- Zależność danych występująca w szczególności przy następstwie obliczeń.
- **Testowanie i debugowanie** są zdecydowanie trudniejsze niż w programach jednowątkowych.

Typy równoległości



Źródło: A. Silberschatz, Operating Systems Concepts Essentials

Dane dzielone są między procesami/rdzeniami wykonującymi **tego samego typu** operacje.

Przykład: sumowanie zakresów komórek.

Zadania dzielone są między procesami/rdzeniami, a każdy wątek realizuje **unikalną** operację.

Przykład: jednoczesne wyznaczanie min i max.

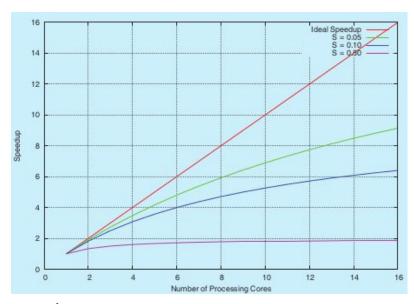
Prawo Amdahl'a

Wyraża potencjalny wzrost wydajności obliczeń przez dodanie kolejnych rdzeni obliczeniowych do obsługi aplikacji, która ma dwa komponenty: podlegający i niepodlegający zrównolegleniu.

S - procentowy udział niepodlegającego zrównolegleniu kodu.

N - liczba rdzeni przypisanych do zadania.

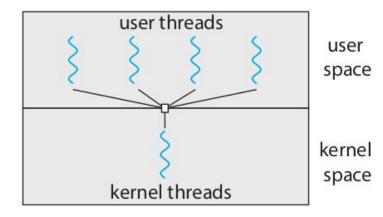
$$speedup \le \frac{1}{S + \frac{(1-S)}{N}}$$



Źródło: A. Silberschatz, Operating Systems Concepts Essentials

Model wielowątkowy - Many-to-One

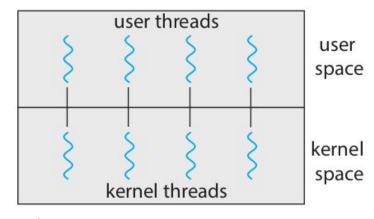
- Zarządzanie wątkami wykonywane jest w przestrzeni użytkownika (przez bibliotekę).
- Zaleta: wydajność.
- Wada 1: zablokowanie całego procesu, jeśli któryś wątek wykona blokujące wywołanie systemowe.
- Wada 2: wątki nie zostaną uruchomione równolegle w systemie wielordzeniowym.
- To tzw. zielone wątki (ang. green threads) można je uruchomić w środowisku nie wspierającym wielowątkowości.
- Przykłady: Solaris, wczesne versje Java.



Źródło: A. Silberschatz, Operating Systems Concepts Essentials

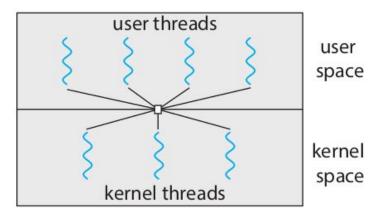
Model wielowątkowy - One-to-One

- Model wprowadza niezależną
 współbieżność, tzn. dany wątek może być
 realizowany także wtedy, gdy inny wywoła
 blokującą funkcję systemową.
- Model wprowadza także równoległość.
- Wada: każdy wątek użytkownika tworzy wątek w jądrze, a duża ich liczba może obniżać wydajność systemu.
- Przykłady: Linux, Windows.



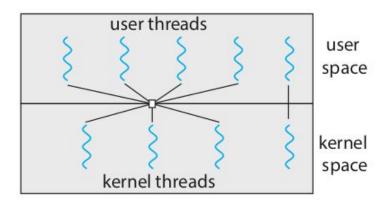
Model wielowątkowy - Many-to-Many

- Model multiplexuje wiele wątków w przestrzeni użytkownika z równą lub mniejszą liczbą wątków w przestrzeni jądra.
- Liczba wątków w przestrzeni jądra może być specyficzna względem aplikacji lub sprzętu.
- Model ten jest pozbawiony wad modeli Many-to-One i One-to-One.
- Trudny w implementacji.



Model wielowątkowy - Two-level

Jak na rysunku obok.



Biblioteki programistyczne dla wątków

- Biblioteki dostarczają API (ang. *Application Programming Interface*) do tworzenia i zarządzania wątkami.
- Podejście 1: Wątki w przestrzeni użytkownika, bez wsparcia ze strony jądra. To oznacza, że wynikiem wywołania funkcji bibliotecznej jest wywołanie funkcji lokalnej, nie systemowej.
- Podejście 2: Wątki w przestrzeni jądra ze wsparciem systemu operacyjnego. To oznacza, że kod i dane biblioteki istnieją w przestrzeni jądra, a wywołanie funkcji jest wywołaniem systemowym.

Biblioteki programistyczne dla wątków (2)

- POSIX Pthreads przestrzeń użytkownika lub przestrzeń jądra.
- Windows thread library przestrzeń jądra.
- Java thread API bezpośrednio w programach Java, tak jak dana implementacja JVM zależna od hostującego systemu operacyjnego.

- POSIX i Windows dane zadeklarowane globalnie są współdzielone między wątkami procesu.
- Java nie ma danych globalnych, dostęp do współdzielonych danych musi zostać nadany.

Strategie tworzenia wątków

Strategia asynchroniczna - wątek tworzy wątek potomny i następnie kontynuuje swoje działanie. Oba wątki działają współbieżnie i niezależnie.

Zastosowanie:

- Serwery wielowątkowe.
- Responsywny interfejs użytkownika.

Strategia synchroniczna - wątek tworzy wątki potomne i przechodzi w stan oczekiwania na zakończenie wykonywania ich zadań. O ile wątki potomne działają współbieżnie, to wątek macierzysty po prostu czeka.

Zastosowanie:

 Obliczenia z przesłaniem zadań cząstkowych i oczekiwaniem na wyniki.

Pula wątków

Powody:

- Tworzenie wątków zajmuje pewien czas (mniejszy niż procesów potomnych), a może mogą być wykorzystane ponownie.
- Brak kontroli liczby powstających wątków może doprowadzić do przeciążenia zasobów (procesor, pamięć) systemu.

Rozwiązanie: pula wątków (ang. thread pool)

- Utworzenie zadanej liczby wątków.
- Umieszczanie wątków w puli wątków.
- Wątki oczekują na przydzielenie zadania.
- Serwer otrzymuje żądanie.
- Serwer przekazuje żądanie do puli wątków.
- Jeśli w puli jest wolny wątek, przejmuje on żądanie i zajmuje się jego obsługą.
- Jeśli brak jest wolnych wątków w puli, zadanie jest kolejkowane.
- Po zakończeniu obsługi danego żądania wątek wraca do puli i oczekuje na nowe.
- Pula wątków najlepiej działa, gdy zadania obsługiwane są asynchronicznie.

Rozmiar puli wątków

Rozmiar puli wątków może być zależny od:

- Liczby rdzeni procesora.
- Ilości fizycznej pamięci RAM.
- Może być też dynamicznie zmieniany w zależności od aktualnie działających wątków (obserwując ich obciążenie).

Wywołania systemowe: fork() oraz exec()

Problem: czy po wywołaniu przez wątek funkcji systemowej fork() proces potomny duplikuje wszystkie wątki, czy nowy proces jest jedno-wątkowy?

Odpowiedź: sprawdzić i odpowiedź przedstawić na forum UPEL.

Działanie: wywołanie exec () spowoduje zastąpienie całego procesu i wszystkich wątków.

Przypadek I: jeśli exec() wywołany jest zaraz po fork(), wówczas duplikowanie wszystkich wątków nie jest potrzebne, bo i tak proces zostanie zastąpiony w funkcji exec().

Przypadek II: jeśli exec () wywołany jest później, dany fork () powinien zduplikować wszystkie wątki.

Obsługa sygnałów

Procedura obsługi sygnałów:

- Sygnał jest generowany przez zdarzenie.
- Sygnał jest dostarczany do procesu.
- Proces musi obsłużyć sygnał.

Sygnał synchroniczny: dzielenie przez 0, nielegalny dostęp do pamięci.

Sygnał asynchroniczny: wciśnięcie np. [ctrl+c].

Zagadka: który wątek otrzyma sygnał?

Obsługa sygnału:

- domyślna obsługa sygnału jeśli brak zdefiniowanej obsługi sygnału, zajmuje się nią jądro systemu operacyjnego (sygnał może być zignorowany lub zakończyć działanie programu),
- zdefiniowana przez użytkownika obsługa sygnału.

Sygnał a program wielowątkowy

Gdzie dostarczyć sygnał?

- Do wątku, do którego sygnał pasuje.
- Do każdego wątku w procesie.
- Do wybranych wątków w procesie.
- Wybrać jeden wątek do przechwytywania wszystkich sygnałów danego procesu.

Wysyłanie sygnału do procesu:

kill(pid_t pid, int signal)

Przechwyci go pierwszy nieblokujący wątek.

Wysyłanie sygnału do wybranego wątku:

pthread_kill(pthread_t tid, int signal)

